

Kexin Chu / 储可新

AI Agent Systems Engineer / LLM Infrastructure

☎ (+86) 157-5515-2633

✉ kexin.chu@uconn.edu

📍 Farmington, CT (Remote preferred)

📄 kexinchu

🌐 kexinchu.github.io

🎓 Scholar

Summary / 个人概述

- UConn CS Ph.D. candidate (Advisor: Prof. Wei Zhang), 研究方向为 LLM Agent 系统的确定性推理、可靠服务与高效调度。
- 4+ 年工程团队研发和团队管理经验, 覆盖 AI Agent 产品从零到一、大规模搜索推荐系统架构、以及生产级 LLM 推理服务 (日均数亿请求)。
- 自研确定性 Agent DAG 编排框架, 主张 Agent 系统的每一步输出可复现、可验证、可追溯; 熟练使用 LangChain / LangGraph 构建生产级 Agent 应用。
- 多篇 ML Systems 方向论文, 涵盖 KV-cache 共享、Agent memory safety、Agent tool routing、MoE 推理加速、向量检索等; 部分发表于 ICDCS/EuroSys/EMNLP 等会议, 其余在审。

Experience / 工作经历

QuarterMill

Technical Lead

Remote

Jun St 2026 – Present

- 带领 6 人工程团队, 从零设计并构建 QuarterMill 核心产品, 负责整体架构决策、迭代节奏与交付管理; 制定技术路线图并主导 code review 与技术方案评审。
- 设计并实现自研确定性 Agent DAG 编排系统: 将文档处理拆解为 OCR/HTR 提取 → 结构化信息解析 → 质量评估 → Claims 生成的多步 Agent pipeline, 确保每一步输出确定性可复现。
- 核心设计哲学: Agent workflow 采用 DAG 编排而非 chain-of-thought 自由生成, 每个 Agent node 有明确的输入 schema、输出 schema 和 deterministic execution guarantee, 拒绝不可控的随机输出。
- 构建核心数据基础设施层: 基于 Nebula (graph DB) 建模实体关系, PGVector 支撑语义检索, PostgreSQL 存储结构化元数据, 三者协同支撑异构文档的存储、检索与关联分析。
- 集成 OCR/HTR pipeline 处理手写体、印刷体、表格等多类文档源, 通过自定义预处理 (去噪、旋转矫正、版面分析) 与后处理 (置信度过滤、跨字段校验) 逻辑将提取准确率提升至生产可用水平。
- 开发 Agent 驱动的质量评估模块: 基于 LLM 自动评估提取信息的完整性与一致性, 生成结构化的 quality score 和 claims, 作为下游决策的输入依据。

Dongchedi / 懂车帝 (ByteDance)

LLM Algorithm Researcher Intern

Shanghai, China / Remote

Apr 2025 – Oct 2025

- 负责"AI 选车"产品的模型部署优化, 该推理服务日均处理 40 万+ 请求, 需要在严格延迟预算 (P99 < 2s) 下服务多个大模型。
- 针对无法装入单台 8×H20 节点的大模型, 设计并实现量化 + offload + prefetch 联合 pipeline, 在显存受限条件下保持推理质量与吞吐。
- 分析并解决跨节点推理中的内存压力与互联数据搬运瓶颈, 通过 profiling 定位 stall 点并设计 compute-communication overlap 策略减少 GPU idle time。
- 与上游模型团队协作确定量化方案 (INT8/FP8), 通过对比实验验证精度损失在业务指标可接受范围内 (准确率下降 < 0.5%)。
- 输出部署方案文档与 best practice, 为团队后续大模型上线提供可复用的标准化部署流程。

Baidu, Inc. / 百度

Senior Software Engineer / Architecture Lead

Beijing, China

Jul 2020 – Aug 2024

- 担任搜索推荐架构负责人, 带领 12 人团队, 覆盖搜索 Push & 推荐、DeepQA 搜索、流式索引和 LLM 权限管控等方向; 4 年内从 T3 晋升至 T5 (跨两级晋升)。
- 设计离线/在线推荐全链路 pipeline: 离线基于 Spark + Hadoop 进行特征计算与大规模数据处理 (日处理数据量 TB 级), 在线基于 Golang + Gin 构建低延迟服务层, 形成完整的数据 → 模型 → 服务编排链路 (与 Agent pipeline 编排理念相通)。
- 将数据新鲜度延迟从 24 小时压缩至 30 分钟, 增量索引延迟从 48 小时压缩至 5 分钟, 支撑日均 6 亿 push 和 1.5 亿日活访问。
- 主导单体 PHP 服务向模块化 Go 微服务的重构, 长尾延迟降低 63%, 显著提升系统可观测性与高并发场景下的检索效率; 引入 gRPC 替代 HTTP 调用, 服务间通信延迟进一步降低。
- 构建百度 LLM 搜索功能的权限管控基础设施 (角色分级、API 限流、灰度策略), 支持安全灰度发布, 上线

后支撑 200 万+ 用户注册。

- 建立团队技术规范：推动代码审查制度、上线 checklist、以及基于 Kafka 的异步消息解耦架构，提升团队工程效率与系统稳定性。

Research / 研究成果

Agent 系统与可靠推理

- *MemKernel* (AAAI 2026, under review)*: 针对 parallel coding agents 中持久化 tool observation 的权限失效问题——observation 在跨 session 复用时其 evidence、依赖或 policy 可能已变更。提出 transactional reference-monitor, enforce lifecycle-serializable authority。在 16,464 次 lifecycle trials 中消除全部 2,426 个 invalid commits, 同时接受所有 1,908 个合法操作。
- *LQM-ContextRoute* (arXiv 2026)*: 针对 LLM Agent 在多个同功能 tool provider 间的路由问题——运行时各 provider 的负载和质量动态变化, 传统 bandit 方法无法适应。提出基于 context-aware routing 的方案, Search F1 提升 2.18 points, StrategyQA 准确率最高提升 18 points (vs. SW-UCB)。
- *MarginGate* (arXiv 2026)*: 针对 batch 推理中 BF16 精度导致的 token flip (同一 prompt 不同 batch size 产生不同输出), 设计选择性验证机制。在不需 always-on verification 的前提下恢复 100% 确定性解码, trigger rate 仅 15–19%, 延迟开销降低最多 2.23x。

LLM Memory Systems

- *MCaM* (ICDCS 2025)*: 通过跨 HBM/DRAM/SSD 三级存储协调 KV-cache 复用, 解决 shared LLM serving 中重复前缀的 prefill 开销。Prefill 延迟降低 69%, 吞吐提升 3.3x。
- *SafeKV* (arXiv 2025)*: 在多租户 LLM serving 中实现隐私安全的 KV-cache 共享——隔离敏感 block 同时保留非敏感前缀的复用。在保护隐私前提下, 吞吐相比严格隔离方案提升 2.66x。
- *ReLACE* (under review)*: 针对动态多模态检索中 OOD query 和在线数据更新导致的 recall 漂移问题, 在变化的 workload 条件下维持 93.7%–97.8% recall。
- *SQLens* (ongoing): 针对 PostgreSQL-based multimodal RAG 后端中 SQL 谓词在 ANN 遍历后过滤导致的效率问题, 在不同 selectivity 设置下实现 1.4x–4.2x 加速。

MoE 推理加速

- *ExpertFlow* (arXiv 2025): 通过自适应 prefetch 和 cache-aware expert routing 解决显存受限 MoE 推理中的 host-GPU expert swap stall, 将 stall time 降至 baseline 的 0.1% 以下。
- *DynaExq* (arXiv 2025): 在严格 GPU 显存预算下动态提升 hot expert 精度 (而非固定 bit-width), 吞吐相比 ExpertFlow 最高提升 2.73x。

Education / 教育背景

University of Connecticut, CT, USA Ph.D. in Computer Science and Engineering, GPA 3.91 Aug 2024 – Present
Advisor: Prof. Wei Zhang 方向: ML Systems, LLM Inference, Deterministic Agent Serving

核心课题: LLM Agent 系统的确定性保障、KV-cache 多级复用、MoE 推理加速

Hefei University of Technology / 合肥工业大学, China M.S. & B.S. in Electrical Engineering Aug 2013 – Jun 2020

本硕连读, 硕士方向为信号处理与机器学习; 在读期间连续获得国家奖学金。

Technical Skills / 技术栈

Languages	Python (精通), C++ (熟练), Go (熟练), SQL (熟练), Bash
Agent / LLM	LangChain, LangGraph, Function Calling, Custom DAG Orchestration, RAG Pipeline, Prompt Engineering, Tool Use Design
ML / Serving	PyTorch, Transformers, vLLM, SGLang, CUDA, ONNX, TensorRT, Quantization (INT8/FP8)
Systems / Data	Linux, FastAPI, Redis, PostgreSQL, PGVector, Nebula, Faiss, DiskANN, Docker, K8s, Git, Kafka, gRPC, Spark, Hadoop
Engineering	系统架构设计, 微服务拆分, CI/CD, 灰度发布, 性能 Profiling, 技术方案评审

Awards / 获奖

- **Predoctoral Fellowship**, University of Connecticut (2025, 2026)
连续两年获得 UConn 博士预科奖学金, 用于支持 ML Systems 方向全职研究。
- **Baidu Pride Special Award** / 百度骄傲特别奖 (2022)
百度年度最高荣誉之一, 授予在公司业务中做出突出贡献的团队/个人, 全公司获奖比例 < 1%。
- **Baidu Breakthrough Innovation Award** / 百度突破创新奖 (2021–2022)
连续两年获得, 表彰在搜索推荐架构创新中的技术突破 (数据时效性优化、微服务重构等)。
- **National Scholarship** / 国家奖学金, 合肥工业大学 (2018, 2019)
中国教育部颁发的最高级别奖学金, 研究生阶段连续两年获得, 获奖比例约为同专业前 2%。